

Implementasi dan Analisis Komparatif Transformer pada Klasifikasi Teks, Vision Transformer, serta Super-Resolution Gambar

Firmansyah Sundana*

NIM: 257150100011009

Mata Kuliah: Topik Pembelajaran Mesin

12 Mei 2026

Ringkasan

Abstrak. Laporan ini menyajikan implementasi *from-scratch* Transformer pada tiga domain: klasifikasi sentimen teks (IMDb), klasifikasi gambar (CIFAR-10) dengan Vision Transformer (ViT), dan tugas non-klasifikasi berupa *Single Image Super-Resolution* memakai Swin2SR *pretrained*. Pada IMDb, Transformer (87,51%) hanya unggul 0,48 pp atas MLP; pada CIFAR-10, SmallResNet (76,17%) mengungguli ViT (66,03%) sebesar 9,5 pp dengan $\sim 3\times$ parameter lebih sedikit. Modifikasi pada Swin2SR berupa *tiled inference* dengan *feathered blending* memungkinkan inferensi pada gambar berukuran sembarang tanpa OOM (selisih piksel $\approx 0,05\%$). Hasil menegaskan bahwa *inductive bias* konvolusional masih relevan pada dataset kecil.

Kata kunci—Transformer, ViT, IMDb, CIFAR-10, Swin2SR, *Tiled Inference*.


1 Pendahuluan

Arsitektur Transformer [1] kini menjadi tulang punggung model modern di NLP, *computer vision*, dan *multimodal learning* berkat mekanisme *self-attention* yang menangkap dependensi jarak jauh tanpa rekurensi atau lokalitas konvolusi. Namun, ketika data terbatas atau tugas didominasi pola lokal, model dengan *inductive bias* sesuai (CNN, LSTM) sering kompetitif atau bahkan unggul [2].

Laporan ini mendokumentasikan eksperimen komparatif pada tiga domain: (i) klasifikasi teks Transformer vs. MLP/CNN-1D [3]/RNN pada IMDb 50K [7]; (ii) klasifikasi gambar ViT [2] vs. MLP/SimpleCNN/SmallResNet [4] pada CIFAR-10 [8]; (iii) modifikasi Swin2SR [5, 6] untuk *Single Image Super-Resolution*. Tujuan utama: memahami implementasi, mengukur *trade-off*, dan memodifikasi kode *open-source* nyata—bukan mengejar akurasi tertinggi.

2 Dataset

IMDb [7]: 50.000 review film berbahasa Inggris berlabel biner, seimbang 25k/25k; split *stratified* 80/20 (*seed*=42). Median panjang review ≈ 173 kata dan persentil ke-90 ≈ 357 kata (Gambar ??-kiri); dipilih *max_len*=256 sebagai baseline. **CIFAR-10** [8]: 60k gambar 32×32 pada 10 kelas (50k/10k); augmentasi *RandomCrop*(padding=4) + *RandomHorizontalFlip* + normalisasi kanonik (Gambar ??-kanan).



Gambar 1: Kiri: distribusi panjang review IMDb (garis merah = *max_len*=256). Kanan: satu sampel per kelas CIFAR-10.

3 Arsitektur Model

Seluruh blok Transformer/ViT ditulis *dari nol* di PyTorch (tanpa `nn.TransformerEncoder` bawaan).

Model Teks (input $(B, T) \rightarrow \text{logits } (B, 2)$): (i) *TransformerClassifier*—Embedding + sinusoidal PE + $2\times$ EncoderBlock (MHA + FFN + LN) + *mean-pool* (abaikan padding) + Linear; $d_{\text{model}}=128$, $h=4$, $L=2$, $d_{\text{ff}}=256$, dropout 0,1. (ii) *MLPClassifier*: Embedding + mean-pool + FC[256, 128] + Linear. (iii) *CNN1D* [3]: Embedding + parallel Conv1d kernel {2, 3, 4} + max-over-time + Linear. (iv) *RNN*: Embedding + 2-layer biRNN + last hidden + Linear.

Model Gambar: (i) *ViT*—PatchEmbed (Conv2d 4×4 , stride 4 $\Rightarrow$ 64 patch) + [CLS] + learnable PE + $6\times$ EncoderBlock + LN + Linear pada [CLS]; $d_{\text{model}}=192$, $h=6$, $L=6$. (ii) *ImageMLP*: Flatten + FC[512, 256].

*Email: sundana@student.ub.ac.id

(iii) *SimpleCNN*: 3 blok Conv-BN-ReLU-Pool ($32 \rightarrow 64 \rightarrow 128$) + GAP, hanya 95k parameter. (iv) *SmallResNet*: stem + 3 stage (6 BasicBlock).

Training: Adam ($\text{lr}=10^{-3}$, $\text{wd}=10^{-5}$), CrossEntropyLoss, 10 epoch, batch 64 (teks)/128 (gambar), seed 42. Hardware: NVIDIA RTX 5060 Ti, 17,1 GB VRAM, PyTorch 2.11 + CUDA 13.


4 Hasil Eksperimen

4.1 Hasil Utama (10 epoch)

Tabel 1 merangkum metrik akhir; kurva training ditunjukkan pada Gambar ??.

Tabel 1: Hasil eksperimen utama text (IMDb) dan vision (CIFAR-10), 10 epoch.

Model	Dataset	Acc	Loss	Params	Train	Inf/batch
Transformer	IMDb	0,8751	0,4827	2,84 M	120,7 s	5,68 ms
MLP	IMDb	0,8703	0,5968	2,63 M	13,9 s	0,46 ms
CNN1D	IMDb	0,8682	0,6280	2,71 M	23,6 s	0,83 ms
RNN	IMDb	0,7723	0,5342	2,73 M	26,8 s	0,84 ms
ViT	CIFAR-10	0,6603	0,9684	1,81 M	134,1 s	10,58 ms
ImageMLP	CIFAR-10	0,4003	1,6271	1,71 M	60,7 s	8,20 ms
SimpleCNN	CIFAR-10	0,6151	1,1253	95 k	69,4 s	9,05 ms
SmallResNet	CIFAR-10	0,7617	0,7594	697 k	114,7 s	8,62 ms



(a) Teks/IMDb

(b) Vision/CIFAR-10


Gambar 2: Kurva *loss* dan *accuracy* (solid: train, putus-putus: test).

4.2 Variasi Hiperparameter Struktural

Transformer dilatih ulang (5 epoch) dengan $\text{max_len} \in \{64, 128, 256, 512\}$ dan ViT dengan $\text{patch_size} \in \{2, 4, 8, 16\}$ (Tabel ??, Gambar 5). Untuk teks, akurasi naik monoton hingga 256; lompatan ke 512 hanya +0,55 pp namun $3\times$ lebih lambat. Untuk ViT, patch kecil ($p=2$, 256 patch) terbaik tapi $5\times$ lebih mahal; patch besar ($p \geq 8$) menghancurkan konten spasial—pada $p=16$ tersisa 4 patch dan akurasi jatuh ke 31,1%.

Tabel 2: Variasi max_len (kiri) dan patch_size (kanan), 5 epoch.


max_len	Acc	Time	patch	#Patch	Acc	Time
64	0,8078	18,8 s	2	256	0,5770	335,4 s
128	0,8469	21,5 s	4	64	0,5444	66,9 s
256	0,8877	60,3 s	8	16	0,3671	48,0 s
512	0,8932	192,4 s	16	4	0,3113	48,2 s



Gambar 3: Pengaruh max_len (kiri) dan patch_size (kanan).


4.3 Confusion Matrix dan Contoh Prediksi

Confusion matrix pada Gambar 6 menunjukkan model teks seimbang antar kelas, sementara pada vision kategori paling sering tertukar adalah *cat* vs *dog* dan *deer* vs *bird*—sesuai intuisi visual (Gambar 7).



Gambar 4: *Confusion matrix* pada uji.

SmallResNet — atas: benar, bawah: salah



Gambar 5: Contoh prediksi SmallResNet (atas: benar; bawah: salah).

5 Swin2SR Super-Resolution (Non-Klasifikasi)


Repository `mv-lab/swin2sr`¹ [5, 6] memberi *Single Image Super-Resolution* (SISR); output berupa tensor RGB beresolusi penuh, bukan probabilitas kelas. Digunakan checkpoint `caidas/swin2SR-classical-sr-x2-64` (12,09 M parameter, skala 2×) dalam mode *inference-only*. Gambar ?? membandingkan LR asli, *bicubic*, dan Swin2SR; Swin2SR memberi tepi tajam dan detail lokal lebih kaya.

Modifikasi—Tiled Inference dengan Feathered Blending. Swin2SR dilatih pada *window* 64 × 64; pada gambar besar, kompleksitas *self-attention* $O(N^2)$ memicu OOM. Fungsi `tiled_super_resolution()` memecah gambar menjadi tile 64 × 64 dengan *overlap* 8 piksel, menjalankan inferensi per tile, lalu menggabungkan output dengan *triangular feather window* agar tidak ada *seam*; fallback ke inferensi biasa untuk gambar ≤ tile. **Validasi:** pada 48×48, selisih piksel *nol* (transparent); pada 128×128, rata-rata selisih 0,139/255 ≈ 0,05% (visual identik,

¹<https://github.com/mv-lab/swin2sr>

Gambar ??-bawah), waktu eksekusi 0,39 s (4 tile).

```
def tiled_super_resolution(pil_img, model, processor,
                          tile=64, overlap=8, scale=2):
    W, H = pil_img.size
    if W <= tile and H <= tile:
        return swin2sr_inference(pil_img, model, processor)
    ramp = np.linspace(0, 1, tile*scale, dtype=np.float32)
    win = np.minimum(ramp, ramp[::-1])
    win2d = (win[:,None]*win[None,:])[:,None]
    # iterate tiles with stride = tile - overlap ...
```



Gambar 6: Atas: LR / bicubic / Swin2SR (128→256). Bawah: *plain* vs *tiled* SR—visual tak dapat dibedakan.

6 Analisis dan Diskusi

Model terakurat & tercepat. Pada teks, Transformer (87,51%) hanya unggul 0,48 pp atas MLP yang 9× lebih cepat (13,9 s vs 120,7 s). Pada vision, SmallResNet (76,17%) mengungguli ViT 9,5 pp dengan parameter ~3× lebih sedikit; SimpleCNN paling efisien (95k parameter, 0,6151).

Apakah Transformer selalu lebih baik? Tidak. CNN unggul pada gambar kecil karena *inductive bias* berupa *translation equivariance* dan *locality* cocok dengan struktur gambar dan 50k sampel CIFAR-10. LSTM/CNN-1D tetap relevan untuk teks pendek: IMDb didominasi kata kunci lokal (“*amazing*”, “*boring*”) yang ditangkap kernel n-gram CNN-1D dengan akurasi 86,82% (hanya 0,7 pp di bawah Transformer) namun 5× lebih cepat.

Kelemahan Transformer pada data kecil. Banyak parameter dan sedikit prior memicu overfitting: pada Transformer/IMDb, *train acc* 97,96% vs *test acc* 87,51% (gap 10 pp). Perlu regularisasi kuat atau *pretraining* masif.

Pengaruh hiperparameter struktural. *Patch size* kecil ($p=2$) terbaik tapi 5× lebih mahal; $p=16$ menyisakan 4 patch dan akurasi jatuh ke 31%. *Sequence length* 64→256 menambah akurasi 8 pp; 256→512 hanya 0,5 pp karena hanya ~10% review >256 kata.

Swin2SR. Input: gambar LR; output: gambar HR 2×—bukan klasifikasi (output piksel, bukan label diskrit). Modifikasi *tiled inference* memungkinkan SR pada gambar berukuran sembarang tanpa OOM dengan output praktis identik (selisih ~0,05%).

7 Kesimpulan

Transformer tidak selalu unggul: pada IMDB hanya 0,5 pp di atas MLP, pada CIFAR-10 kalah 9,5 pp dari SmallResNet (parameter $\sim 3\times$ lebih sedikit). *Inductive bias* konvolusional dan rekuren tetap relevan pada dataset kecil dan teks pendek. Hiperparameter struktural (*patch size*, *sequence length*) sangat menentukan—*sweet spot* bergantung karakteristik data. Untuk SISR, Swin2SR *state-of-the-art*, dan modifikasi *tiled inference* membuatnya praktis untuk gambar berukuran sembarang dengan output praktis identik. Kode lengkap tersedia di `main.py`, `transformer_assignment.ipynb`, modul `models/` dan `utils/`; eksekusi penuh ≈ 22 menit pada RTX 5060 Ti.

Pustaka

- [1] A. Vaswani *et al.*, “Attention is all you need,” NeurIPS, 2017.
- [2] A. Dosovitskiy *et al.*, “An image is worth 16×16 words,” ICLR, 2021.
- [3] Y. Kim, “CNNs for sentence classification,” EMNLP, 2014.
- [4] K. He *et al.*, “Deep residual learning for image recognition,” CVPR, 2016.
- [5] M. V. Conde *et al.*, “Swin2SR: SwinV2 transformer for compressed image super-resolution,” ECCV Workshops, 2022. <https://github.com/mv-lab/swin2sr>
- [6] J. Liang *et al.*, “SwinIR: Image restoration using Swin transformer,” ICCV Workshops, 2021.
- [7] A. L. Maas *et al.*, “Learning word vectors for sentiment analysis,” ACL, 2011.
- [8] A. Krizhevsky, “Learning multiple layers of features from tiny images,” Tech. Rep., Univ. Toronto, 2009.